DIPLOMADO EN CIENCIA DE DATOS · GEN. 33 · FES ACATLÁN

Análisis de Clusters Global Air Quality & Deforestation

Javier Martinez Reyes

35,000 registros

12 variables

2014–2023

Seed 333

Fuente: Kaggle — Global Air Quality and Respiratory Health Outcomes

Dataset & Variables

35,000	12	0	2014–2023
registros	variables numéricas	valores nulos	cobertura temporal

Variables incluidas en PCA

- **AQI** Índice de calidad del aire
- **PM2.5 / PM10** Partículas en suspensión
- **CO2_Emissions_MT** Emisiones de CO_2
- **Vehicles_Increase_%** Crecimiento vehicular
- **Industries_Increase_%** Crecimiento industrial
- **Deforestation_Rate_%** Tasa de deforestación
- **Afforestation_Rate_%** Tasa de reforestación
- **Env_Budget_Million_USD** Presupuesto ambiental
- **Population_Density** Densidad poblacional
- **Green_Space_Ratio_%** Ratio de áreas verdes
- **Avg_Life_Expectancy** Esperanza de vida

Matriz de Correlación — Hallazgos Clave

Las correlaciones extremadamente altas justifican el uso de PCA — hay información redundante que comprimir.

0.96

AQI ↔ PM2.5

Contaminación atmosférica forma una sola dimensión

0.97

AQI ↔ PM10

PM2.5, PM10 y AQI son casi idénticos

-1.00

AQI ↔ Life Expectancy

Correlación perfecta inversa — a más AQI, menos años de vida

0.92

CO_2 ↔ Vehículos

Presión industrial y vehicular son el mismo factor

-0.66

Env_Budget ↔ AQI

Invertir en medio ambiente reduce contaminación

-0.77

Green Space ↔ CO_2

Más áreas verdes correlaciona con menos emisiones

Resultados del PCA

3 componentes explican ≥ 80% de la varianza total

PC1 (~55%)

Contaminación e Impacto en Salud

- AQI, PM2.5, PM10 (+)
- CO_2, Vehículos, Industrias (+)
- Life Expectancy, Green Space (−)

PC2 (~15%)

Presión sobre el Territorio

- Deforestation_Rate (+)
- Afforestation_Rate (−)
- Population_Density (+)

PC3 (~10%)

Inversión Ambiental

- Env_Budget_Million_USD (+)
- Residual de correlaciones
- moderadas con el resto

Determinación del k óptimo

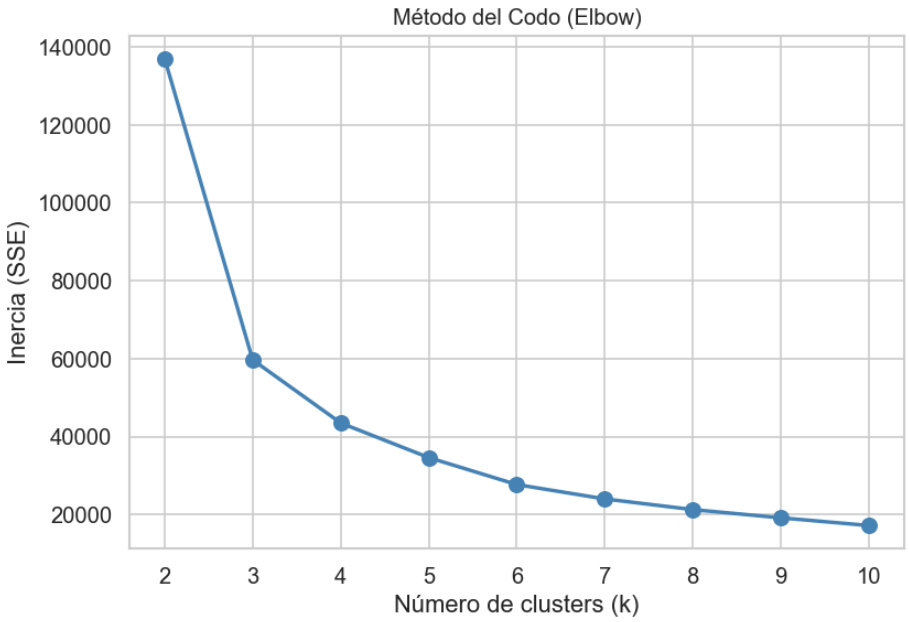

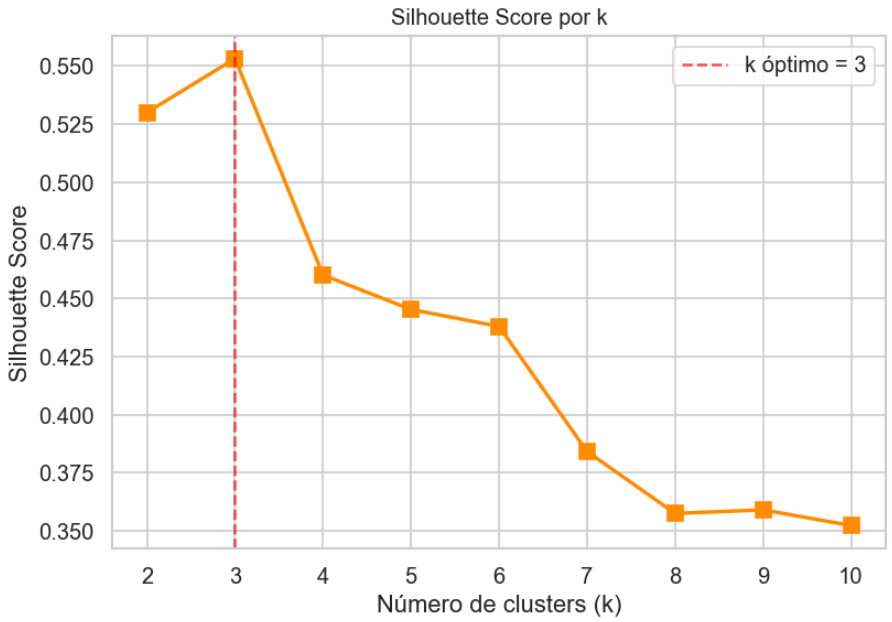

k = 3 seleccionado: codo pronunciado + Silhouette Score máximo (≈ 0.52)

Perfil Estadístico de Clusters

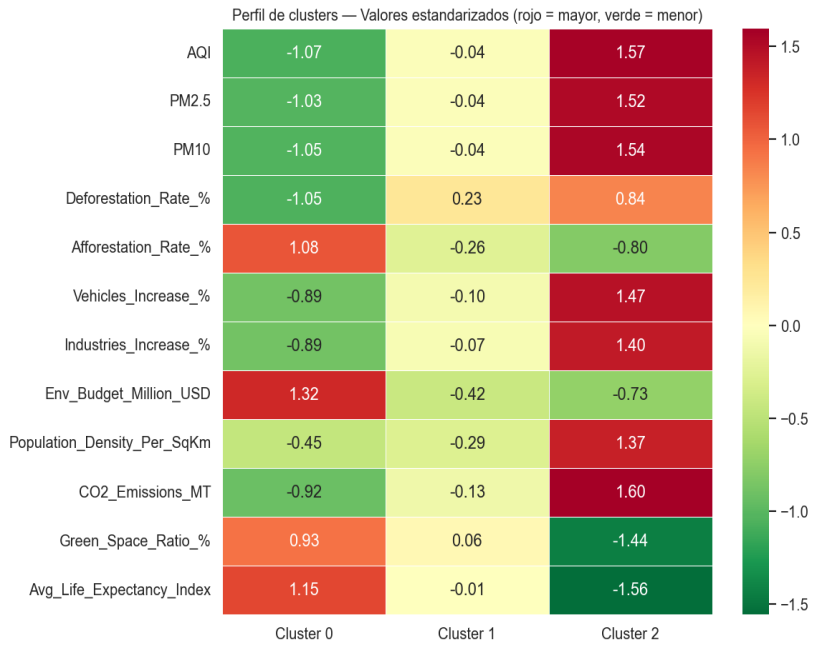

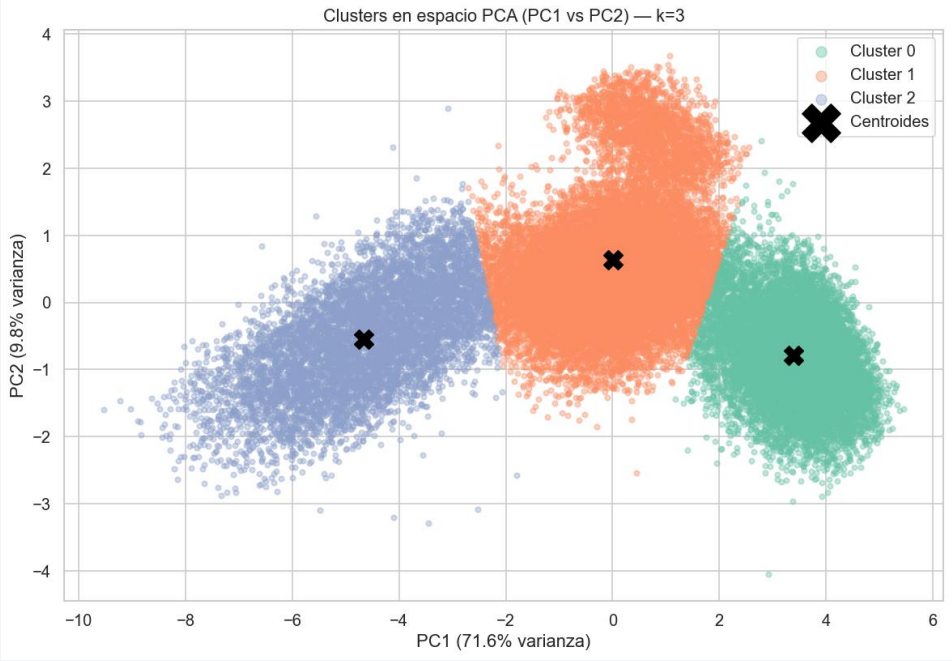

El heatmap revela perfiles opuestos: Cluster 0 presenta bajos niveles de contaminación y alta inversión ambiental; Cluster 1 muestra valores neutros; Cluster 2 concentra los indicadores más críticos — AQI, CO_2 y partículas extremadamente altos, con la menor esperanza de vida del grupo.

El scatter plot muestra 3 clusters bien separados en el espacio PCA. PC1 (71.6% de varianza) es el eje dominante que separa claramente los grupos. Los centroides confirman separación espacial significativa, validando que K-Means encontró estructuras reales en los datos.

Interpretación de Clusters

Cluster 0 Gestión Ambiental Avanzada (9,598 registros)

España · Suecia · Australia · Canadá · Japón

- AQI, PM2.5, CO_2 muy por debajo del promedio (−1.0 a −1.1)
- Mayor presupuesto ambiental del grupo (+1.34)
- Alta reforestación (+1.10) y áreas verdes (+0.96)
- Esperanza de vida más alta (+1.15)

Cluster 1 Economías en Transición (18,276 registros)

Rusia · Etiopía · Indonesia · Perú · Sudáfrica

- Todos los indicadores cercanos a 0 — perfil neutro
- Ligera deforestación por encima del promedio (+0.24)
- Menor inversión ambiental que Cluster 0
- Grupo más heterogéneo y numeroso

Cluster 2 Crisis Ambiental y Presión Demográfica (7,126 registros)

Egipto · Irán · Pakistán · Bangladesh · Myanmar

- AQI (+1.58), CO_2 (+1.62) y partículas (+1.53/+1.55) extremos
- Vehículos (+1.49) e industrias (+1.42) creciendo sin control
- Menor esperanza de vida (−1.55) y casi sin áreas verdes (−1.46)
- Alta densidad poblacional agrava el impacto (+1.37)

Conclusiones

01

PCA justificado

Correlaciones de 0.96–0.97 entre AQI, PM2.5 y PM10, y correlación perfecta (−1.00) entre AQI y esperanza de vida confirman alta redundancia — PCA es la herramienta correcta.

02

Reducción eficiente

3 componentes capturan ≥80% de la varianza de 12 variables. PC1 domina con ~55% representando el eje principal de contaminación.

03

Clusters bien separados

Silhouette Score ≈ 0.52 indica clusters coherentes. La geografía valida los resultados: países desarrollados, en transición y en crisis ambiental.

04

Hallazgo crítico

Cluster 2 (Egipto, Pakistán, Bangladesh) concentra los peores indicadores — AQI +1.58, CO_2 +1.62, esperanza de vida −1.55. La contaminación tiene consecuencias medibles en salud.